OPCIÓN 3: COMENTAR IMÁGENES AUTOMÁTICAMENTE

Generación Automática de Descripciones de Imágenes

Arquitectura Encoder-Decoder con MobileNetV2 y LSTM — Proyecto Final
Proyecto Final de Deep Learning

¿Puede una red neuronal describir lo que ve? Este proyecto construye un sistema multimodal multimodal que combina visión por computador y procesamiento de lenguaje natural para natural para generar captions textuales a partir de imágenes.

Curso

Deep Learning — Proyecto Final

Dataset

Flickr8k

Integrantes

Grupo — Proyecto Final Final

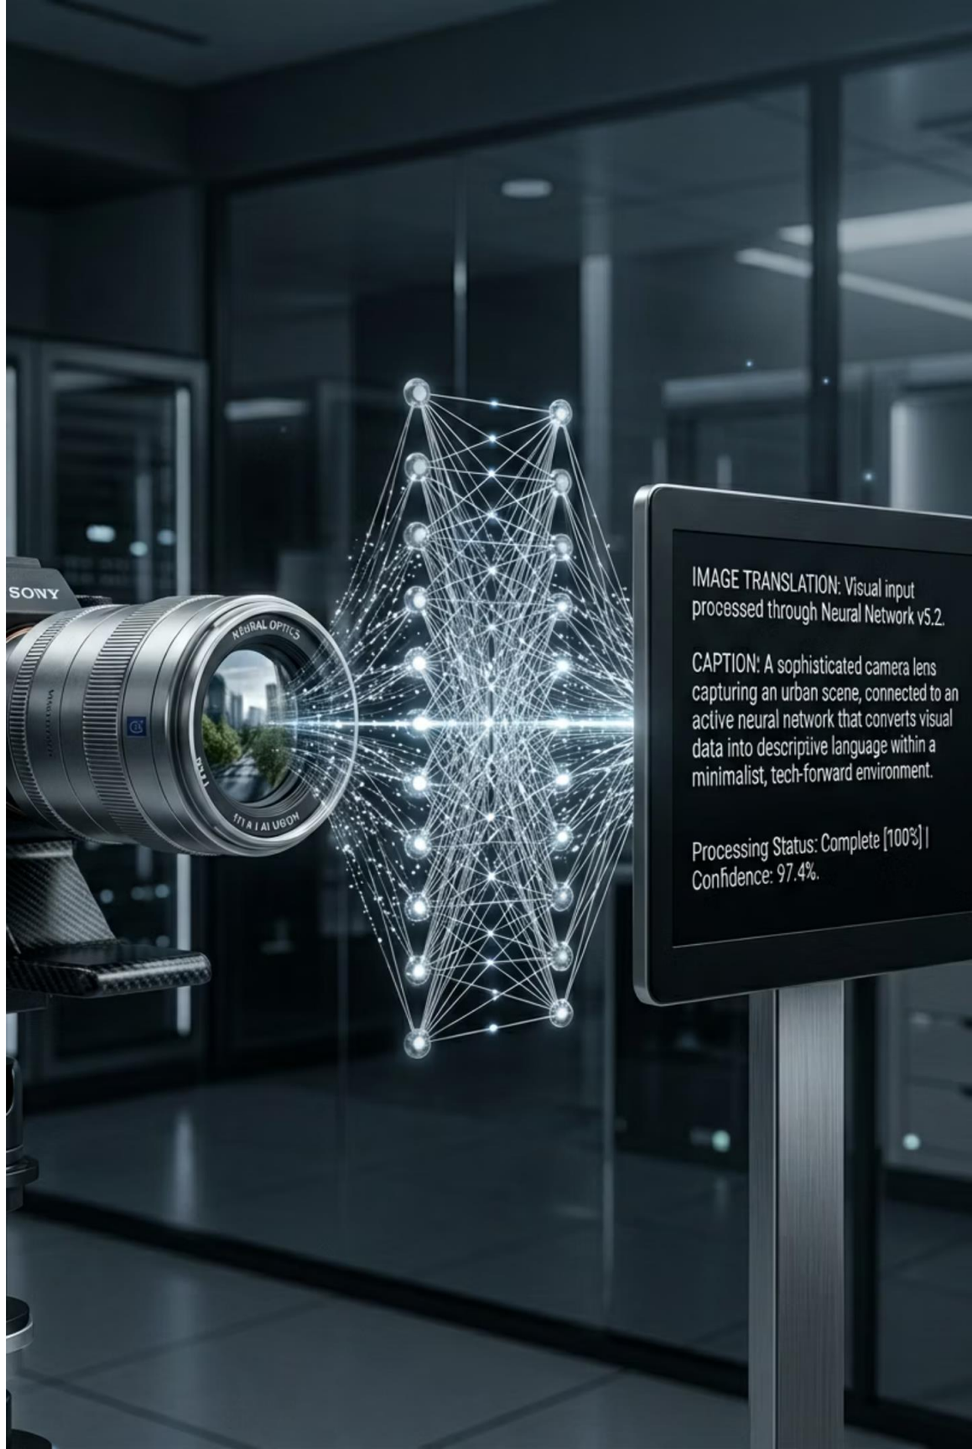

Problema y Pregunta de Interés

Problema

Construir un sistema de *image captioning captioning* que reciba una imagen como como entrada y genere automáticamente automáticamente una descripción textual textual coherente. El reto central es integrar visión por computador y PLN en PLN en una solución multimodal de extremo a extremo.

Pregunta de Interés

¿Es posible generar descripciones útiles y útiles y semánticamente consistentes para para imágenes usando una arquitectura arquitectura Encoder-Decoder basada en basada en MobileNetV2 y LSTM, calibrada calibrada con las técnicas vistas en el curso?

Utilidad Práctica

- Accesibilidad para personas con con discapacidad visual
- Indexación y búsqueda semántica de imágenes
- Generación automática de alt-text y text y metadatos
- Apoyo a aplicaciones multimedia y multimedia y sistemas de recuperación de información

Dataset: Flickr8k

Flickr8k es un benchmark estándar para *image captioning*, compuesto por por imágenes cotidianas con descripciones escritas por humanos. Su tamaño tamaño manejable y su variedad temática lo hacen adecuado para entrenar y entrenar y evaluar modelos Encoder-Decoder en entornos académicos.

8091

Imágenes

40455

Captions totales

5

Captions por imagen

7251

Palabras en vocabulario

38

Tokens máximos

¿Por qué Flickr8k?

- Escenas cotidianas diversas, representativas del dominio visual visual general
- Múltiples captions por imagen permiten evaluación con BLEU multirreferencia
- Ampliamente utilizado como baseline en literatura de *image image captioning*
- Tamaño computacionalmente viable para entrenamiento académico

Exploración de Datos

Partición del Dataset

El split se realizó **por imagen** para evitar data leakage: ninguna imagen aparece en más de una de una partición.

Partición	Imágenes	% del total
Train	5663	69.9%
Validación	1213	15.0%
Test	1215	15.0%
Total	**8091**	**100%**

Split por imagen evita data leakage entre particiones.

Hallazgos Exploratorios

- **Distribución:** Mayoría entre 8–20 tokens; máximo 38.
- **Vocabulario:** 7251 palabras; predominan sustantivos y verbos de acción.
- **Temática:** Escenas al aire libre, personas, animales y deportes.

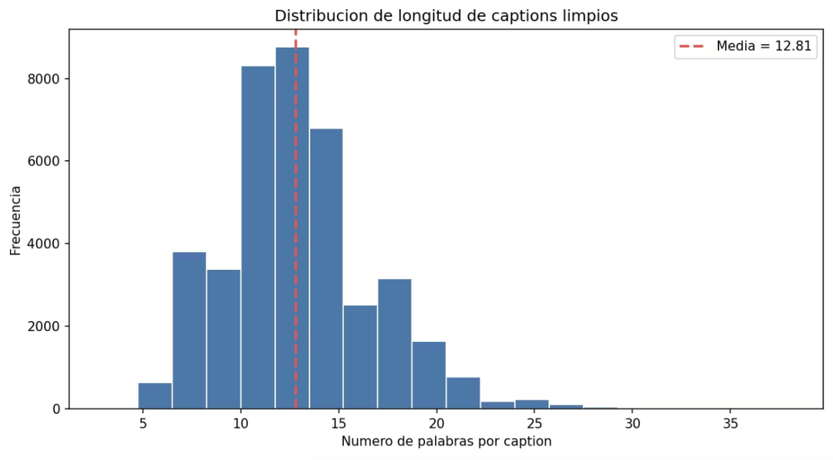

Distribución de longitud de captions limpios

Ejemplo de imagen con captions de referencia:

1. a person doing the backstroke in an outdoor pool
2. a person swimming in a pool next to some chairs and a table
3. a swimmer doing backstrokes in a pool
4. person doing backstroke in pool
5. the person is swimming on their back in a pool

Ejemplo de imagen con captions de referencia

Preparación de Datos

Procesamiento Textual

- Conversión a minúsculas y eliminación de caracteres especiales
- Normalización de espacios y tokens irrelevantes
- Adición de marcadores `startseq` y `endseq`
- Tokenización con `Keras Tokenizer` (vocabulario: 7251 palabras)
- Padding a longitud máxima de 38 tokens

Procesamiento Visual y Pares Supervisados

- Extracción de features con MobileNetV2 preentrenada en ImageNet
- Vector de 1280 dimensiones por imagen, sin fine-tuning del encoder
- Construcción de pares: `[features, secuencia parcial] → siguiente palabra`
- Formulación como clasificación multiclase sobre el vocabulario completo

Selección del Modelo

Encoder-Decoder

Paradigma estándar para tareas de generación condicional. El encoder extrae una representación compacta; el decoder genera secuencias condicionadas en ella. Directamente conectado con los contenidos del curso sobre modelos generativos.

CNN como Encoder Visual

MobileNetV2 preentrenada en ImageNet transfiere conocimiento visual robusto mediante *transfer learning*. Su arquitectura arquitectura liviana es eficiente computacionalmente, ideal para el alcance alcance académico del proyecto.

LSTM como Decoder

Las redes LSTM modelan dependencias a largo largo plazo en secuencias, superando limitaciones del MLP simple en generación de generación de texto. Su celda de memoria memoria permite capturar coherencia gramatical y semántica en los captions generados.

La combinación CNN + LSTM para image captioning es el punto de partida estándar en la literatura (Vinyals et al., 2015) y articula directamente los módulos de visión y NLP vistos en el curso.

Arquitectura Propuesta

Pipeline Encoder-Decoder

Encoder
MobileNetV2 imagen → vector 1280-dim

Decoder
Embedding + LSTM de 256 unidades

Salida
Dense + Softmax sobre 7251 palabras

Componentes del Modelo

01

Encoder Visual

MobileNetV2 fijo extrae vector de características de 1280 dims. Sin actualización de pesos durante entrenamiento.

02

Capa de Embedding

Transforma índices de palabras en vectores densos de representación semántica.

03

Decoder LSTM

Recibe features visuales + secuencia parcial y predice la siguiente palabra en cada paso.

04

Capa Softmax

Proyección densa sobre vocabulario completo (7251 palabras). Entrenamiento como clasificación clasificación multiclase.

Baseline Inicial: MobileNetV2 + GRU

Descripción del Baseline

Como punto de referencia mínimo, se entrenó un modelo con MobileNetV2 como encoder y una encoder y una celda GRU como decoder. Este baseline establece el rendimiento esperado sin esperado sin optimización de hiperparámetros.

0.486

BLEU-1

Precisión unigrama

0.328

BLEU-2

Precisión bigrama

Captura semántica global

El baseline identifica correctamente el contexto general de la escena en la mayoría de los casos.

Fallos en detalle fino

Dificultad para describir relaciones entre objetos, conteo y escenas ambiguas.

Referencia justificada

Sirve como umbral mínimo para justificar la exploración de arquitecturas más complejas complejas (LSTM, hiperparámetros).

Ejemplos cualitativos: caption predicho vs. referencia real.

Calibración Inicial: Comparación de Decoders

Manteniendo fijo el encoder (MobileNetV2) y el pipeline de datos, se compararon tres configuraciones de decoder para identificar la arquitectura base más eficaz.

Modelo	val_loss	val_acc	BLEU-1	BLEU-2	Tiempo (min)
lstm_256 ✓	**3.3898**	**0.3687**	**0.6130**	**0.4244**	**9.98**
gru_128	3.4465	0.3580	0.5936	0.4052	9.88
gru_256	3.4735	0.3508	0.6026	0.4081	8.63

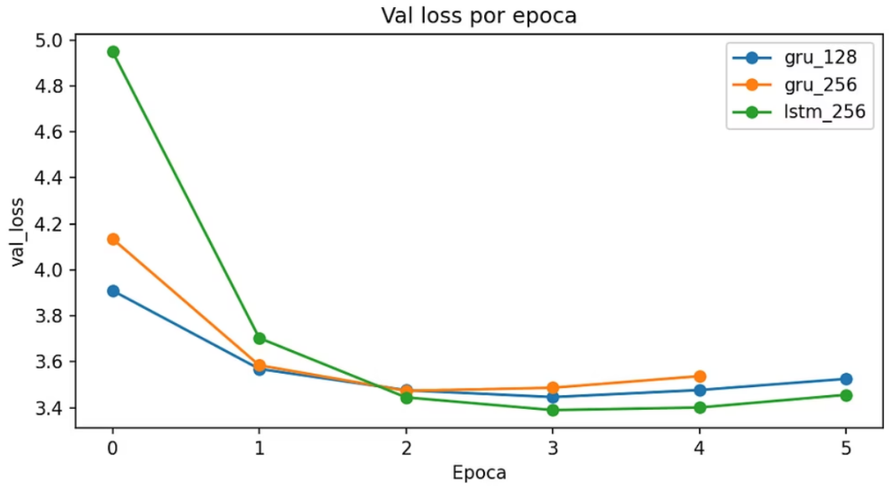

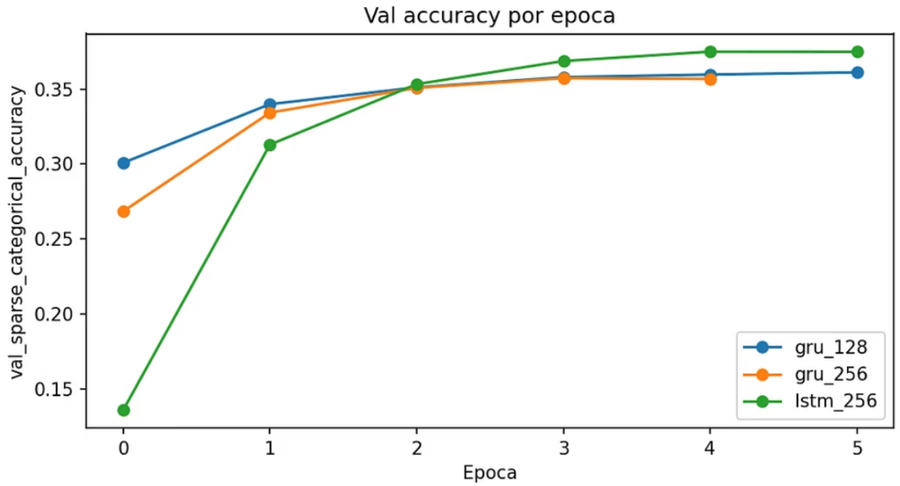

Conclusión

El modelo **lstm_256** obtuvo el menor val_loss (3.3898) y los mejores puntajes BLEU en ambas métricas. Se selecciona como mejor decoder entrenado y punto de partida para la calibración fina.

Notas Metodológicas

- LSTM supera a GRU en esta tarea gracias a su mayor capacidad para modelar dependencias largas
- Mayor número de unidades (256 vs 128) no siempre implica mejor generalización
- El tiempo de entrenamiento es comparable entre configuraciones

Curvas de val_loss y val_accuracy por época para cada configuración de decoder.

Calibración Fina: Exploración de Hiperparámetros

Partiendo del mejor modelo anterior (lstm_256 del Notebook 03), se exploraron variaciones en tasa de aprendizaje, dropout y tamaño de unidades LSTM. **Estos experimentos corresponden exclusivamente al Notebook 04.**

Configuración	val_loss	val_acc	BLEU-1	BLEU-2	Variación
lstm_256_base	3.4977	0.3650	0.5357	0.3638	LR estándar
lstm_256_lowlr	3.3635	0.3710	0.5392	0.3715	LR reducida
lstm_256_lowdrop	3.3624	0.3714	0.4809	0.3331	Dropout bajo
lstm_384_lowlr	3.4355	0.3595	0.5425	0.3719	Más unidades

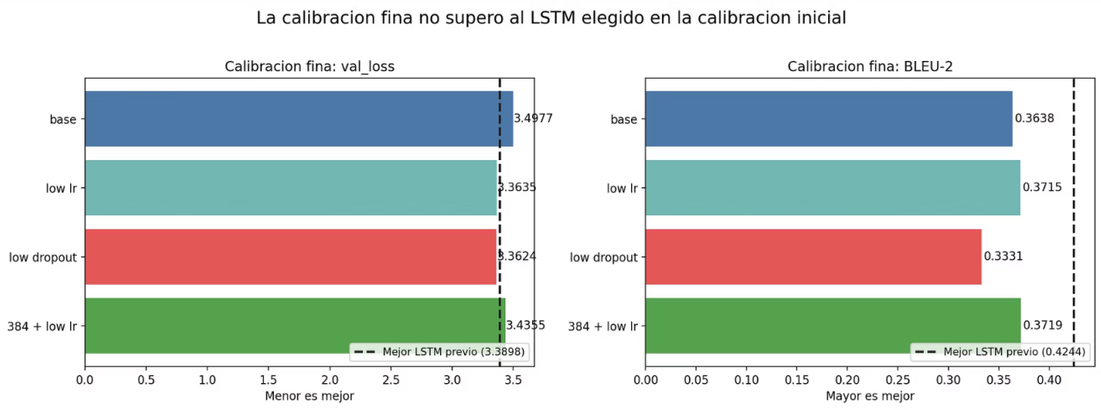

Comparación visual: val_loss y BLEU-2 entre configuraciones de calibración fina.

Observaciones

- La reducción de LR mejora val_loss pero no se traduce en mejor BLEU
- Dropout bajo produce overfitting implícito: BLEU-1 cae a 0.48
- Aumentar unidades a 384 no aporta mejoras consistentes

Conclusión Crítica

Algunas configuraciones mejoraron marginalmente el val_loss, pero **ninguna superó al lstm_256 del Notebook 03 en métricas BLEU**. Se confirma lstm_256 (calibración inicial) como el **mejor modelo entrenado final**.

Comparación de Estrategias de Inferencia

Greedy vs. Beam Search

Greedy Decoding

Selecciona la palabra de mayor probabilidad local en cada paso. paso. Rápido pero subóptimo globalmente: puede quedar atrapado en soluciones locales.

Beam Search

Mantiene las *k* mejores secuencias secuencias candidatas en paralelo y paralelo y selecciona la frase con con mayor probabilidad acumulada acumulada al finalizar.

Resultados — Mismo Modelo Entrenado (lstm_256)

Estrategia	BLEU-1	BLEU-2	seg/imagen
Greedy	0.6130	0.4244	0.37
Beam k=3	0.6222	0.4354	1.13
Beam k=5	0.6306	0.4495	1.83

Recomendación final: Beam k=3 ofrece el mejor balance calidad–tiempo. Beam k=5 es óptimo numéricamente pero triplica el tiempo de inferencia respecto a Greedy.

Mejor modelo entrenado

MobileNetV2 + LSTM(256) — Calibración inicial

Mejor inferencia numérica

Beam Search k=5 (BLEU-2: 0.4495)

Inferencia recomendada

Beam Search k=3 — balance calidad/velocidad

Resultados Cualitativos

Espacio reservado para grilla de resultados: imagen | caption de referencia | caption predicho por el modelo.

Fortalezas Observadas

- Reconoce correctamente el contexto general de la escena
- Detecta objetos prominentes prominentes y acciones frecuentes
- Genera descripciones plausibles y gramaticalmente coherentes

Errores y Limitaciones Cualitativas

- En escenas ambiguas genera captions genéricos o alucinados
- Combina patrones frecuentes frecuentes del corpus con información visual, lo que puede producir frases plausibles pero incorrectas incorrectas
- Dificultad con detalle fino: conteo de objetos, atributos de color, relaciones espaciales

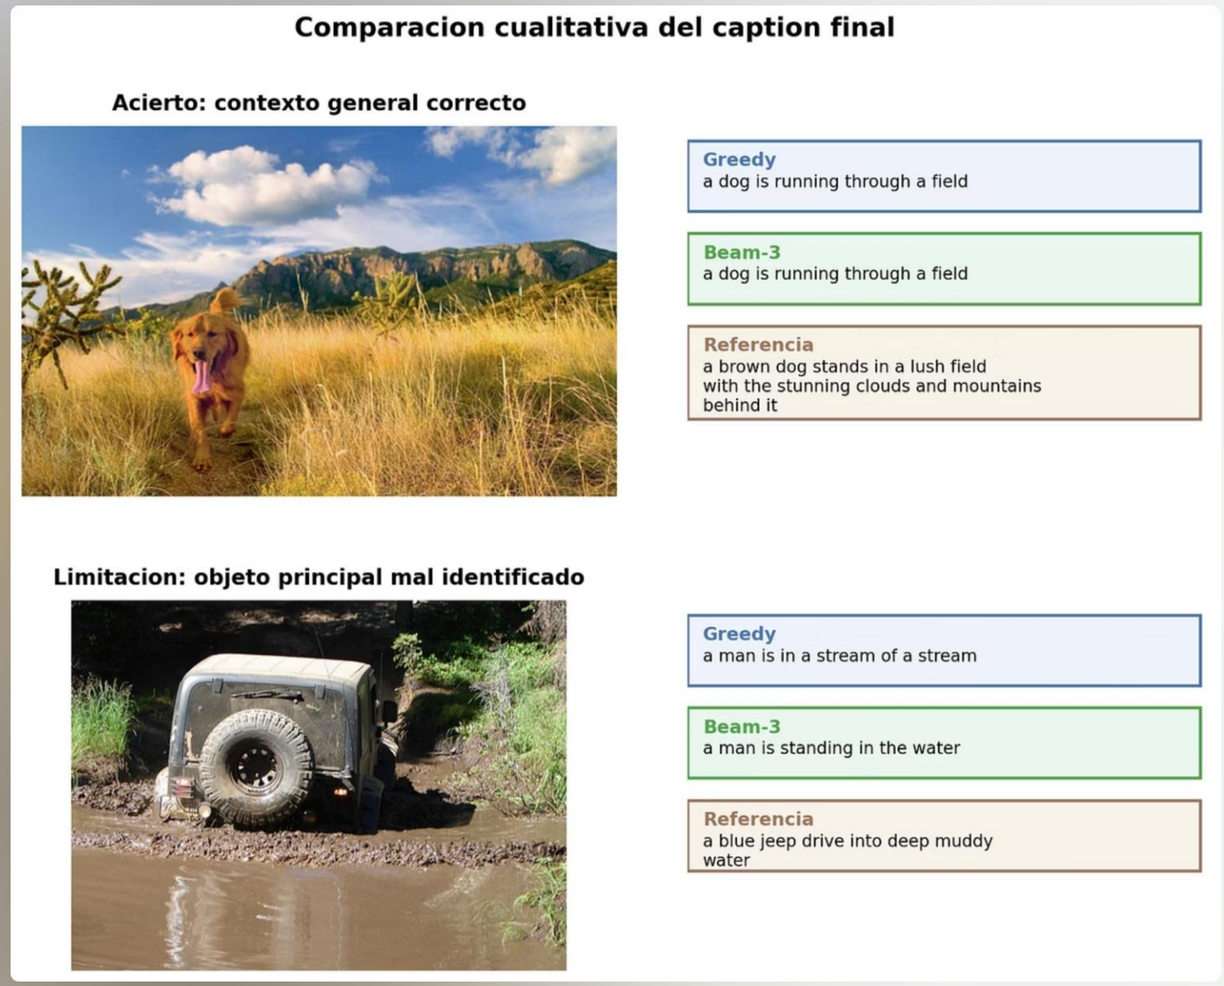

Relevancia, Limitaciones y Trabajo Futuro

Relevancia de la Solución

Sistema funcional de *image captioning* end-to-end con tecnologías del curso (CNN, LSTM, transfer learning)

Impacto real: accesibilidad, búsqueda semántica, metadatos automáticos

Pipeline reproducible y metodológicamente riguroso

Limitaciones Identificadas

- Dataset relativamente pequeño (8091 imágenes)
- Captions de referencia con alta variabilidad entre anotadores
- Encoder fijo: sin mecanismo de atención ni fine-tuning visual
- Errores persistentes en detalle fino y conteo de objetos
- Captions genéricos en escenas complejas o poco frecuentes

Trabajo Futuro

Mecanismos de Atención

Incorporar atención visual (Bahdanau, Transformer) para que el modelo focalice focalice regiones relevantes al generar cada palabra.

Encoders más Potentes

Explorar ResNet, EfficientNet o Vision Transformers (ViT) como extractores de características visuales más expresivos.

Dataset Ampliado

Escalar a MSCOCO (330K imágenes) para mejorar la generalización y reducir y reducir el sesgo hacia escenas frecuentes.

Métricas Adicionales

Evaluar con METEOR y CIDEr para complementar BLEU y capturar mejor capturar mejor la diversidad semántica de los captions.

Conclusiones

Mejor Modelo Entrenado

MobileNetV2 + LSTM(256) — Calibración Calibración inicial (Notebook 03)
BLEU-1: 0.6130 | BLEU-2: 0.4244 | val_loss: 3.3898

Mejor Estrategia de Inferencia

Beam Search k=3 recomendado por balance balance calidad–velocidad.
Beam k=5 es óptimo numérico: BLEU-1: 0.6306 | BLEU-2: 0.4495

01

El sistema construido es funcional, reproducible reproducible y metodológicamente coherente de coherente de principio a fin.

02

La calibración sistemática (baseline → inicial → inicial → fina → inferencia) permitió justificar justificar cada decisión con evidencia cuantitativa.

03

El proyecto demuestra viabilidad práctica del *image captioning* con arquitecturas accesibles, abriendo la puerta a extensiones con atención y encoders avanzados.

OPCIÓN 3: COMENTAR IMÁGENES AUTOMÁTICAMENTE

DEEP LEARNING — PROYECTO FINAL